1. Cel testu

Celem testu było sprawdzenie zachowania trzywęzłowego klastra Proxmox VE z Ceph podczas awarii jednego noda. Maszyna VM 306 była zarządzana przez klaster HA i korzystała z dysku na Ceph.

Test obejmował:

- utratę jednego noda klastra,
- reakcję Proxmox HA,
- zmianę stanu OSD w Ceph,
- sprawdzenie dostępności VM,
- weryfikację integralności danych.

2. Przebieg testu

Wszystkie trzy nody są aktywne, klaster posiada quorum, a trzy OSD pracują w stanie `up/in`. Pool wykorzystywany przez VM 306 jest skonfigurowany: **size = 3, min_size = 2**

```
root@i7:~# pvecm status
Cluster information
-------------------
Name:             lab-cluster
Config Version:   10
Transport:        knet
Secure auth:      on

Quorum information
------------------
Date:             Thu Oct  1 17:27:16 2026
Quorum provider:  corosync_votequorum
Nodes:            3
Node ID:          0x00000003
Ring ID:          1.5f0
Quorate:          Yes

Votequorum information
----------------------
Expected votes:   3
Highest expected: 3
Total votes:      3
Quorum:           2
Flags:            Quorate

Membership information
----------------------
    Nodeid      Votes Name
0x00000001          1 192.168.0.21
0x00000002          1 192.168.0.20
0x00000003          1 192.168.0.22 (local)
root@i7:~#
```

```
root@i7:~# ceph -s
  cluster:
    id:     02a86b5c-cb6e-4fe4-8071-6795c73b9fb5
    health: HEALTH_OK

  services:
    mon: 3 daemons, quorum proxmox,i7,pve (age 2h) [leader: proxmox]
    mgr: pve(active, since 7h), standbys: proxmox
    osd: 3 osds: 3 up (since 2h), 3 in (since 2h)

  data:
    pools:   3 pools, 65 pgs
    objects: 1.15k objects, 4.2 GiB
    usage:   12 GiB used, 288 GiB / 300 GiB avail
    pgs:     65 active+clean

  io:
    client:   0 B/s rd, 0 B/s wr, 0 op/s rd, 0 op/s wr
```

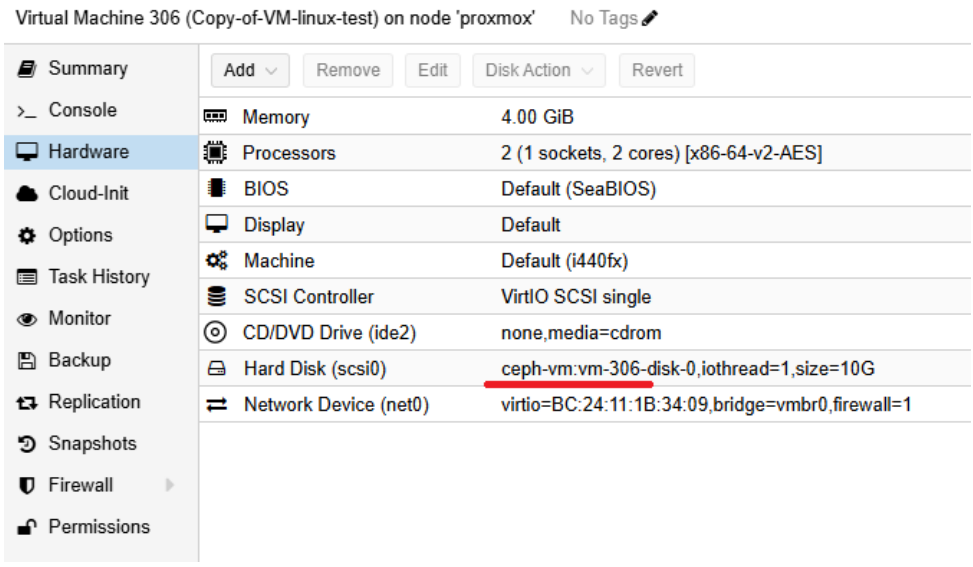
Rys. 1. Stan początkowy klastra Proxmox VE i Ceph.

Maszyna VM 306 działa na nodzie `proxmox` i jest zarzadzana przez Proxmox HA

```
root@i7:~# ha-manager status
quorum OK
master pve (active, Thu Oct  1 17:30:27 2026) - dynamic load CRS (load imbalance: 40.0%)
fencing armed (CRM watchdog active)
lrm i7 (idle, watchdog standby, Thu Oct  1 17:30:32 2026)
lrm proxmox (active, watchdog active, Thu Oct  1 17:30:24 2026)
lrm pve (idle, watchdog standby, Thu Oct  1 17:30:32 2026)
service vm:306 (proxmox, started)
root@i7:~#
```

Rys. 2. Maszyna VM 306 - Proxmox HA.

Dysk maszyny VM 306 znajduje się na storage `ceph-vm`, dostępnym z wszystkich nodów klastra.



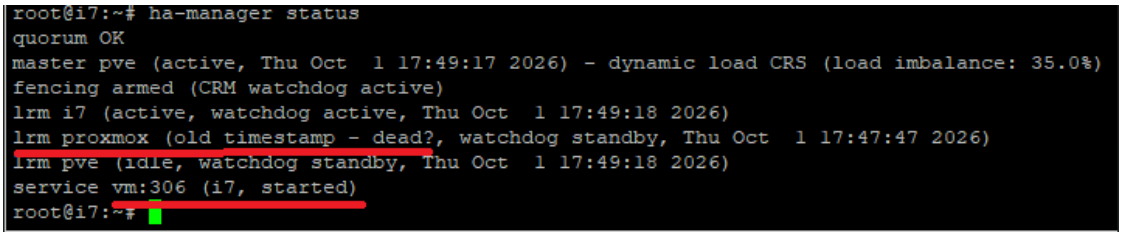
Rys. 3. Dysk maszyny VM 306 przechowywany na storage Ceph

Przed rozpoczęciem testu utworzono plik kontrolny i obliczono jego sumę

```
root@306:~# hostname
ip -br addr
uptime
sha256sum /root/test-ceph.img
306
lo               UNKNOWN        127.0.0.1/8 ::1/128
ens18            UP             192.168.0.225/24 fe80::be24:11ff:felb:3409/64
 17:44:00 up 0 min,  1 user,  load average: 0,00, 0,00, 0,00
a7c744c13cc101ed66c29f672f92455547889cc586ce6d44fe76ae824958ea51  /root/test-ceph.img
root@306:~#
```

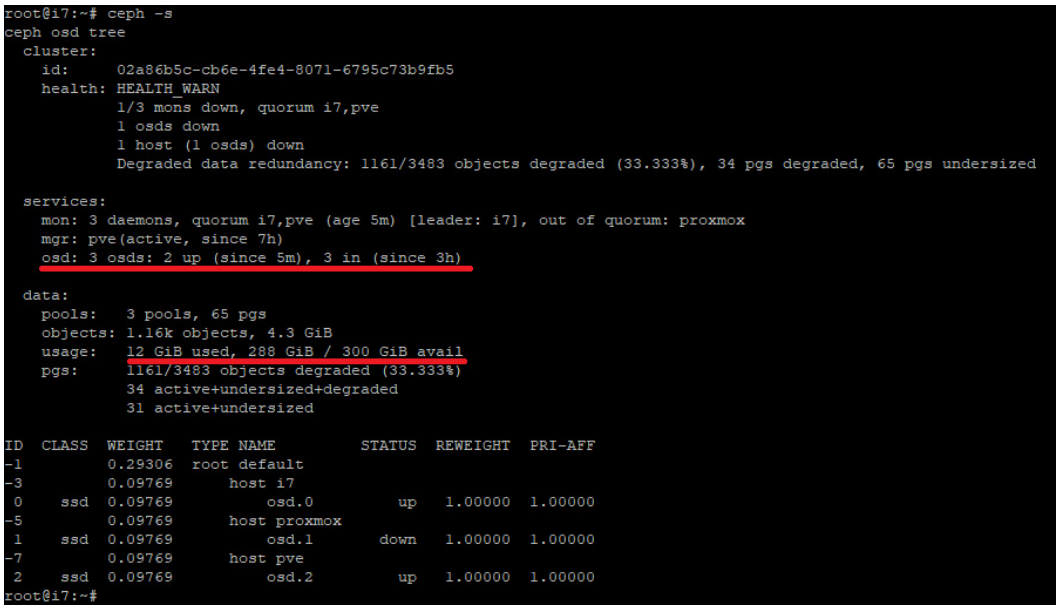
Rys. 4. Suma SHA-256 pliku kontrolnego przed awarią noda.

Następnie wyłączono node `proxmox`, na którym w tym momencie działała maszyna VM 306. Mechanizm HA wykrył niedostępność noda i automatycznie uruchomił VM 306 na nodzie `i7`.



Rys. 5. Automatyczne uruchomienie VM 306 na nodzie `i7` po awarii noda `proxmox`.

Bezpośrednio po awarii noda `proxmox` znajdujący się na nim `osd.1` został oznaczony jako `down`, ale nadal pozostawał w stanie `in`. Ceph raportował w tym momencie: **3 osds: 2 up, 3 in** . Dostępna pojemność klastra nadal uwzględniała wszystkie trzy OSD: **usage: 12 GiB used, 288 GiB / 300 GiB avail**



Rys. 6. Stan Ceph bezpośrednio po awarii noda - `osd.1` w stanie `down+in`, przy nadal uwzględnianej pojemności wszystkich trzech OSD.

Po około 600 sekundach Ceph automatycznie oznaczył `osd.1` jako `out`. Liczba OSD pozostających w stanie `in` zmniejszyła się z 3 do 2: **3 osds: 2 up, 2 in** Jednocześnie dostępna pojemność klastra zmniejszyła się: **usage: 7.7 GiB used, 192 GiB / 200 GiB avail** Ceph przestał więc uwzględniać około 100 GiB pojemności należącej do `osd.1`.

Dodatkowo polecenie: **ceph osd dump | grep '^osd.1'** potwierdziło stan: **osd.1 down out ... autoout**

```
root@i7:~# ceph -s
ceph osd tree
  cluster:
    id:     02a86b5c-cb6e-4fe4-8071-6795c73b9fb5
    health: HEALTH_WARN
            1/3 mons down, quorum i7,pve
            Degraded data redundancy: 1161/3483 objects degraded (33.333%), 34 pgs degraded, 65 pgs undersized

  services:
    mon: 3 daemons, quorum i7,pve (age 15m) [leader: i7], out of quorum: proxmox
    mgr: pve(active, since 7h)
    osd: 3 osds: 2 up (since 15m), 2 in (since 5m)

  data:
    pools:   3 pools, 65 pgs
    objects: 1.16k objects, 4.3 GiB
    usage:   7.7 GiB used, 192 GiB / 200 GiB avail
    pgs:     1161/3483 objects degraded (33.333%)
             34 active+undersized+degraded
             31 active+undersized

  io:
    client:   0 B/s rd, 0 B/s wr, 0 op/s rd, 0 op/s wr

ID  CLASS  WEIGHT   TYPE NAME         STATUS  REWEIGHT  PRI-AFF
-1         0.29306  root default
-3         0.09769      host i7
 0    ssd  0.09769          osd.0         up   1.00000  1.00000
-5         0.09769      host proxmox
 1    ssd  0.09769          osd.1       down         0  1.00000
-7         0.09769      host pve
 2    ssd  0.09769          osd.2         up   1.00000  1.00000
```

Rys. 7. Automatyczne przejście `osd.1` do stanu `down+out` i zmniejszenie dostępnej pojemności klastra po `autoout`.

Pomimo utraty noda `proxmox` maszyna VM 306 działała na nodzie `i7` i pozostawała dostępna przez sieć. **Test wykonano po około 5 godzinach od wystąpienia awarii.** Na maszynie ponownie obliczono sumę SHA-256 pliku kontrolnego i uzyskano tę samą wartość. Dodatkowo wykonano pomyślną próbę zapisu danych.

```
root@306:~# uptime
 23:03:28 up  5:14,  1 user,  load average: 0,00, 0,00, 0,00
root@306:~# sha256sum /root/test-ceph.img
a7c744c13cc10ed66c29f672f92455547889cc586ce6d44fe76ae824958ea51  /root/test-ceph.img
root@306:~#  dd if=/dev/urandom of=/root/test-po-awarii.bin bs=1M count=100 status=progress
100+0 records in
100+0 records out
104857600 bytes (105 MB, 100 MiB) copied, 1,01575 s, 103 MB/s
root@306:~# sync
root@306:~# sha256sum /root/test-po-awarii.bin
f044c9f265bc14323e990df7224b1bb22224075bc79ac1063d16cce338e30fdc  /root/test-po-awarii.bin
root@306:~#
```

Rys. 8. Dostępność maszyny VM 306 po awarii noda klastra.